

La Veille de Nicolas

Jeudi 8 octobre 2026 — édition du soir

5 sujet(s)

Sommaire

1. Claude Haiku 5.5 : un petit modèle annoncé comme le moins cher et le plus rapide
2. Docker Agent : créer, exécuter et partager des agents d'IA en YAML
3. Healthleap lève 38 millions de dollars pour son IA qui repère les patients à risque
4. Nouveaux paramètres de dépôt pour configurer l'accès aux demandes de tirage
5. Claude Opus 5.5 visualise les Villes invisibles d'Italo Calvino

Claude Haiku 5.5 : un petit modèle annoncé comme le moins cher et le plus rapide

L'éditeur de la gamme Claude présente Haiku 5.5, son plus petit modèle, conçu pour les tâches répétitives à fort volume. Le billet, repris sur Hacker News, détaille aussi les tarifs, les résultats annoncés et les nouveautés pour les développeurs.

Le billet de présentation de Claude Haiku 5.5, publié sur Hacker News, émane de l'éditeur de la gamme Claude, qui parle de « nos » modèles. Selon l'éditeur, Haiku 5.5 est son modèle le moins cher, le plus rapide et le plus capable à ce jour dans sa catégorie. Il est destiné aux tâches répétitives à fort volume et sensibles au coût, comme les résumés, le compactage de contexte, les requêtes de base de données et la classification. Il peut aussi servir de sous-agent aux modèles Opus 5.5 et Sonnet 5.5 pour le travail de code, et convient aux usages où la vitesse compte, comme le support client en direct ou l'utilisation du navigateur.

Côté tarifs, le billet indique que Haiku 5.5 coûte beaucoup moins cher que Haiku 4.5. Pour les requêtes allant jusqu'à 100 000 jetons, le prix d'entrée passe de 1,00 \$ à 0,10 \$ par million de jetons, et celui de sortie de 5,00 \$ à 0,50 \$. Au-delà de 100 000 jetons, la baisse est de 50 % selon le même document. L'éditeur affirme qu'en moyenne le coût d'utilisation baisse d'environ 75 %. Il précise que 90 % des requêtes adressées à l'ancien Haiku entraient dans la première catégorie, et que le nouveau tokenizer consomme un peu plus de jetons par tâche, ce qui est pris en compte dans ce calcul. Par ailleurs, le prix des lectures de cache de Sonnet 5.5 est divisé par deux, de 0,20 \$ à 0,10 \$ par million de jetons. Selon l'éditeur, cela réduit d'environ 20 % le coût de Sonnet

5.5 sur la plupart des tâches agentiques.

Les résultats cités sont ceux de l'éditeur. Sur Humanity's Last Exam sans outils, il annonce 45,9 % pour Haiku 5.5, contre 10,2 % pour Haiku 4.5 ; avec outils, 57,4 % contre 18,7 %. Sur OSWorld 2.1, sous-ensemble hors ligne, il indique 72,4 % contre 15,7 % pour Haiku 4.5 et 48,9 % pour GPT-6 Luna. Sur Terminal-Bench 4.0, il annonce 39,2 %, contre 70,6 % pour Sonnet 5.5. Le billet reconnaît que Sonnet 5.5 et Opus 5.5 restent de meilleurs choix pour les tâches de code agentique complexes. Ces chiffres n'ont pas été vérifiés de façon indépendante. Le billet renvoie à une fiche système pour le détail des méthodes d'évaluation.

Sur la sécurité, l'éditeur affirme que Haiku 5.5 présente de nettes améliorations d'alignement par rapport à Haiku 4.5, avec moins de comportements non alignés. Ses garde-fous en cybersécurité sont plus stricts que ceux de Haiku 4.5 mais moins que ceux appliqués à Sonnet 5.5, tout en bloquant encore les tests d'intrusion. Le modèle est disponible sur Amazon Web Services, Google Cloud et Microsoft Azure, sous l'identifiant `claude-haiku-5-5`. L'éditeur annonce aussi un crédit mensuel d'API : 100 \$ par mois pour les abonnés Max 5x, 200 \$ pour Max 20x, et jusqu'à 500 \$ mutualisés pour les équipes. Enfin, les SDK Python et TypeScript prennent en charge, en bêta, l'utilisation de l'ordinateur et du navigateur.

L'essentiel

- Claude Haiku 5.5 vise les tâches répétitives à fort volume et peut servir de sous-agent aux modèles plus grands.
- Selon l'éditeur, son coût d'utilisation baisse d'environ 75 % en moyenne par rapport à Haiku 4.5, des chiffres non vérifiés de façon indépendante.
- Pour un développeur : les SDK Python et TypeScript prennent en charge, en bêta, l'utilisation de l'ordinateur et du navigateur avec l'identifiant `claude-haiku-5-5`.

Sources lues

Hacker News — anthropic.com — posté sur HN le 7 oct. 2026 — publié le 7 oct. 2026

Docker Agent : créer, exécuter et partager des agents d'IA en YAML

Le billet publié sur Hacker News présente docker-agent, une extension de la CLI Docker qui permet de créer et lancer des agents d'IA décrits dans un fichier YAML. Il met en avant la coordination de plusieurs agents, l'accès à des serveurs MCP et le partage des agents via un registre OCI.

Le texte présente docker-agent comme un outil qui permet de construire, lancer et partager des agents d'IA sans écrire de code, à partir d'une configuration déclarative. Un agent se définit dans un fichier YAML : on y précise le modèle, une description, une instruction et la liste des outils. L'exemple donné utilise un agent nommé root, fondé sur le modèle openai/gpt-5-mini, auquel est rattaché le serveur MCP docker:duckduckgo.

L'architecture multi-agents permet de créer des équipes d'agents spécialisés qui se répartissent les tâches automatiquement. Les agents peuvent utiliser des outils intégrés, comme la réflexion, les tâches à faire et la mémoire, ainsi que n'importe quel serveur MCP, qu'il soit local, distant ou fonctionne dans Docker. Le texte mentionne aussi une fonction de recherche documentaire (RAG) reposant sur BM25, des représentations vectorielles, une recherche hybride et un reclassement des résultats.

Côté fournisseurs, docker-agent ne dépend pas d'un modèle en particulier : le texte cite OpenAI, Anthropic, Gemini, AWS Bedrock, Mistral, xAI et Docker Model Runner, entre autres. Les agents peuvent être publiés dans n'importe quel registre OCI, puis récupérés et exécutés ailleurs. Le billet donne aussi des exemples de commandes,

comme `docker agent run` pour lancer l'agent par défaut ou `docker agent new` pour en générer un de façon interactive.

Pour l'installation, trois voies sont indiquées. Avec Docker Desktop en version 4.63 ou supérieure, l'extension est préinstallée. Avec Homebrew, il suffit de lancer `brew install docker-agent`. Enfin, les binaires publiés sur GitHub Releases peuvent être liés symboliquement dans `~/.docker/cli-plugins/docker-agent`. Il faut aussi définir au moins une clé d'API, ou utiliser Docker Model Runner pour un modèle local. Le texte indique enfin que l'outil collecte des données d'usage anonymes afin de l'améliorer.

L'essentiel

- `docker-agent` permet de définir des agents en YAML, de les faire collaborer entre eux et de les partager via un registre OCI.
- Il accepte plusieurs fournisseurs de modèles, dont OpenAI, Anthropic et Docker Model Runner pour les modèles locaux.
- Pour un développeur : après l'installation et la définition d'une clé d'API, la commande `docker agent run agent.yaml` lance une configuration locale.

À vérifier dans les sources : trois

Sources lues

Hacker News — github.com — posté sur HN le 7 oct. 2026 — publié le 1 sept. 2025 — *ancien*

Healthleap lève 38 millions de dollars pour son IA qui repère les patients à risque

La jeune pousse Healthleap, fondée en Afrique du Sud, a levé 38 millions de dollars pour une intelligence artificielle qui signale les patients hospitalisés susceptibles de nécessiter un examen plus attentif. Selon TechCrunch, qui en a eu l'exclusivité, ce financement combine un tour d'amorçage et une série A.

TechCrunch, dans un article signé Ram Iyer, annonce que la société Healthleap a réuni 38 millions de dollars en amorçage et en série A. Le tour d'amorçage, de 8 millions de dollars, est codirigé par Sequoia Capital et First Round Capital. La série A, de 30 millions de dollars, est menée par Hummingbird Ventures. L'entreprise ne communique pas sa valorisation.

Fondée en 2022 en Afrique du Sud par la sœur et le frère Jemima et Josiah Meyer, la société a d'abord proposé un outil de nutrition clinique conçu par Jemima pour les diététiciens. Elle s'est ensuite réorientée vers une plateforme plus générale, destinée à repérer les patients admis à l'hôpital qui peuvent souffrir de dénutrition ou de confusion mentale aiguë, deux affections souvent détectées trop tard. Josiah Meyer, directeur général et cofondateur, explique à TechCrunch que les signes les plus révélateurs figurent dans les notes écrites par les soignants.

La plateforme se connecte au dossier électronique du patient et utilise des modèles de langage pour extraire des mentions comme une perte de poids récente ou des difficultés à avaler. Ces informations sont ensuite combinées aux résultats d'analyses et aux constantes vitales dans des modèles de risque. Selon Josiah Meyer, chaque nuit le système examine chaque patient adulte hospitalisé, puis chaque matin

il inscrit un score de risque dans le flux de travail de l'équipe soignante, avec un tableau de bord détaillant l'évolution des patients. L'entreprise précise que son logiciel ne pose aucun diagnostic et se contente de signaler des éléments à examiner.

Selon Healthleap, la plateforme est déployée dans plus de 50 hôpitaux, contre 3 partenaires il y a un an. Parmi ses clients figurent Penn Medicine, Cedars-Sinai, Intermountain, Houston Methodist et Emory Healthcare. Toujours selon l'entreprise, son chiffre d'affaires aurait été multiplié par plus de 10 sur la même période, sans chiffre précis communiqué. Les contrats, d'une durée de 3 ans, sont facturés selon le nombre de lits autorisés, avec une part liée aux résultats. Selon Josiah Meyer, chaque client a constaté un retour sur investissement d'au moins 5 fois le prix du contrat, et dans certains cas plus de 20 fois sur un an.

Les recherches citées par TechCrunch suggèrent que 20 % à 50 % des patients hospitalisés seraient dénutris. Certaines études lient la dénutrition à des séjours plus longs, à une cicatrisation altérée, à des infections et à une morbidité ou une mortalité plus élevées. Pour l'hôpital de l'Université de Pennsylvanie, Healthleap affirme que son programme de dénutrition aurait généré un impact financier annualisé de 23,8 millions de dollars, dont 6,3 millions de remboursements supplémentaires et 17,5 millions liés à la réduction des durées de séjour. Ces chiffres n'ont pas été vérifiés de façon indépendante.

L'entreprise prévoit d'utiliser les fonds levés pour l'ingénierie, le produit, les ventes et la relation client, ainsi que pour ajouter la détection de nouvelles affections. Selon Josiah Meyer, des programmes visant la pneumopathie d'inhalation, les ulcères de pression et le risque de réadmission pour insuffisance cardiaque congestive sont en cours de

validation clinique. Il vise à terme plus de 40 grandes affections, ainsi qu'une extension aux soins ambulatoires et aux soins à domicile.

L'essentiel

- Healthleap a levé 38 millions de dollars, dont 8 millions en amorçage et 30 millions en série A, selon TechCrunch.
- Son outil analyse les notes cliniques et les données structurées pour signaler des patients hospitalisés à examiner, sans poser de diagnostic.
- Selon l'entreprise, la plateforme est utilisée dans plus de 50 hôpitaux, mais ses résultats financiers n'ont pas été vérifiés de façon indépendante.

Sources lues

TechCrunch — techcrunch.com — 7 oct. 2026

Nouveaux paramètres de dépôt pour configurer l'accès aux demandes de tirage

Les mainteneurs disposent désormais de 2 paramètres pour mieux contrôler la manière dont leurs dépôts acceptent les contributions. Un billet signé Allison en détaille le fonctionnement, les usages visés et les limites actuelles.

Le billet, signé Allison, présente 2 réglages qui permettent d'adapter la gestion des demandes de tirage aux besoins de chaque projet. Selon ce texte, ces paramètres sont disponibles dès maintenant pour tous les dépôts publics et privés, dans Paramètres, puis Général, puis Fonctionnalités.

Le premier réglage permet de désactiver entièrement les demandes de tirage, au même titre que les wikis, les tickets, les discussions et les projets. L'onglet correspondant n'apparaît alors plus : personne ne peut consulter les demandes existantes ni en ouvrir de nouvelles. Le billet cite les dépôts miroirs, les codes en lecture seule et les projets partagés publiquement sans gestion des contributions comme cas d'usage typiques.

Le second réglage limite la création de demandes aux seuls collaborateurs, c'est-à-dire aux utilisateurs disposant d'un accès en écriture. Dans ce cas, l'onglet reste visible et chacun peut lire les demandes et y commenter. Les collaborateurs s'ajoutent ou se retirent depuis l'onglet Collaborateurs des paramètres. Le texte indique que cette option aide à maîtriser la qualité des contributions pendant les phases critiques du développement.

Le billet signale deux limites. L'application mobile n'a pas encore reçu l'ensemble des changements d'interface : si les demandes sont désactivées, l'onglet y reste affiché, même si personne ne peut en créer. Par ailleurs, pour limiter temporairement l'activité de certains utilisateurs sur un dépôt public, les limitations d'interaction temporaires restent disponibles.

L'essentiel

- Deux paramètres permettent soit de désactiver entièrement les demandes de tirage, soit de restreindre leur création aux collaborateurs disposant d'un accès en écriture.
- Pour un développeur : ces réglages se trouvent dans Paramètres, Général, Fonctionnalités, et la gestion des collaborateurs se fait depuis l'onglet Collaborateurs.
- L'application mobile affiche encore l'onglet des demandes même lorsqu'elles sont désactivées, les changements d'interface y étant encore en préparation.

Sources lues

Hacker News — github.blog — posté sur HN le 6 oct. 2026 — publié le 13 févr. 2026 — *ancien*

Claude Opus 5.5 visualise les Villes invisibles d'Italo Calvino

Piotr Migdał, qui crée des visualisations de données et des explications interactives, a confié la même consigne à GPT-6 Astra et à Claude Opus 5.5 pour représenter les Villes invisibles. Il juge le résultat de Claude impressionnant, même si le temps réellement employé par le modèle diffère de ce qu'il affirme lui-même.

Le billet, publié sur Hacker News, est signé Piotr Migdał. L'auteur y raconte avoir demandé à deux modèles d'intelligence artificielle de produire une visualisation interactive du recueil d'Italo Calvino, qui présente 55 villes imaginaires, chacune associée à une émotion ou à un état d'esprit.

La consigne demandait une visualisation en three.js avec pnpm, sans question de la part du modèle, et indiquait que celui-ci disposait de 6 heures de travail. Selon l'auteur, GPT-6 Astra a livré un résultat complet de bout en bout, mais chargé de concepts et de commentaires superflus, qui ajoutent du bruit visuel. Le rendu reprend aussi le style qu'il attribue à Claude, avec un fond beige et des numéros du type 05.

Claude Opus 5.5 a affirmé avoir utilisé à peu près la moitié des 6 heures. L'auteur conteste cette déclaration : d'après lui, le modèle n'a travaillé que 1 heure 25. Il avance toutefois que 6 sous-agents tournant en parallèle représenteraient environ 7 heures de travail d'agent, ce qui expliquerait l'écart. Les sources se contredisent donc sur la durée réelle de l'exécution.

L'auteur précise que ses appréciations sont subjectives. Il estime que GPT-6 Astra est un peu meilleur que Fable 5.1 pour la vue d'ensemble,

le respect des intentions du prompt et la vérification du bon fonctionnement. Le résultat de Claude l'a fait réagir avec enthousiasme, mais aucune mesure indépendante n'est fournie pour étayer ce jugement.

Pour conclure, l'auteur invite ses lecteurs à reprendre la même consigne avec d'autres modèles ou d'autres outils. Il pense que l'IA sera largement utilisée dans la conception, tout en se demandant quelle place il occupera lui-même dans la création de médias interactifs.

L'essentiel

- Piotr Migdał a confié la même consigne à GPT-6 Astra et à Claude Opus 5.5 pour visualiser les Villes invisibles de Calvino.
- Claude Opus 5.5 a déclaré avoir utilisé environ la moitié des 6 heures, alors que l'auteur mesure 1 heure 25 de travail effectif.
- Les appréciations de l'auteur restent subjectives et ne reposent sur aucune mesure indépendante.

Sources lues

Hacker News — quesma.com — posté sur HN le 8 oct. 2026 — publié le 7 oct. 2026